

Roadmap Optimasi Menuju Peringkat Teratas

Apa yang perlu diganti, dipertahankan, dan diuji ulang pada repository DS_JOINTS

TUJUAN DOKUMEN

Mengubah repo saat ini dari kumpulan eksperimen yang sudah kuat menjadi pipeline kompetisi yang valid, terukur, dan reproducible. Fokus utama: mengecilkan gap local CV vs leaderboard sebelum menambah kompleksitas model.

Status repo yang diaudit

Aspek	Temuan pada snapshot repo	Implikasi
Leaderboard	README mencatat 0.47303; notebook mencatat 0.46890 sebagai hasil terbaik.	Dokumentasi hasil perlu diseragamkan.
Local CV	Repo mencatat OOF sekitar 0.34738-0.34828 pada beberapa eksperimen.	Gap terhadap leaderboard perlu dijelaskan sebelum tuning lanjutan.
Arsitektur	Two-stage hurdle + XGBoost/CatBoost + shrinkage + banyak eksperimen.	Fondasi kuat; masalah utama sekarang adalah validasi dan konsistensi pipeline.
Feature engineering	98-ish features, termasuk priors dan empirical transition ratio.	Beberapa feature target-derived harus dibuat fold-safe untuk evaluasi.
Reproducibility	Ada 5-fold training, tetapi object model yang disimpan bukan seluruh ensemble fold.	Package final berisiko tidak identik dengan prediksi submission.

CATATAN PENTING

Tidak ada metode yang menjamin juara 1. Roadmap ini ditujukan untuk memaksimalkan kualitas prediksi secara disiplin berdasarkan metric kompetisi, kondisi data test, dan hasil eksperimen yang sudah ada.

1. Prioritas Perubahan

Prioritas	Yang diubah	File utama	Dampak yang diharapkan
P0 - wajib	Buat validation yang benar-benar leak-free dan time-aware.	train_*.py + modul CV baru	Tahu skor model yang dapat dipercaya.
P0 - wajib	Hilangkan leakage pada cinema/city priors dan empirical transition saat OOF.	feature_engineering.py	Mengurangi OOF optimism.
P0 - wajib	Satu mapping categorical untuk train/valid/test pada XGBoost.	train_podium_90f_gpu.py, solution.ipynb	Menghindari mismatch encoding test.
P0 - wajib	Simpan ensemble semua fold atau retrain model final dengan prosedur identik.	solution.ipynb, train_*.py	Reproducibility aman.
P1 - tinggi	Per-horizon direct hurdle D4-D10.	script baru / train_*.py	Menangkap distribusi berbeda tiap horizon.
P1 - tinggi	Gunakan konteks `test_history`: movie/cinema/city context.	feature_engineering.py	Menangani cold-start film dan context test.
P1 - tinggi	Uji target normalized `z = y/scale` vs raw ticket pada validation yang sama.	model training	Selaras dengan MASE.
P2 - selektif	KNN archetype, stacking, weekend calibration.	test_knn..., benchmark..., scripts baru	Eksperimen tambahan setelah baseline valid.
P2 - jangan dulu	Deep learning yang makin kompleks.	train_deep*.py	Belum prioritas sebelum leakage/validation selesai.

Urutan kerja yang disarankan: P0 -> ukur ulang -> P1 -> ukur ulang -> ensemble OOF -> baru P2.

2. PO - Bersihkan Leakage pada Validasi

MASALAH UTAMA

Feature yang dihitung dari seluruh `train\_raw` sebelum GroupKFold membuat OOF bukan pengukuran yang sepenuhnya out-of-fold. Untuk final training, memakai seluruh train memang boleh; untuk evaluasi fold, statistik tersebut harus dihitung dari data training fold saja.

Temuan	Lokasi	Perubahan yang diperlukan
Cinema prior global	`train_podium_90f_gpu.py` sekitar line 87-103	Pindahkan perhitungan prior ke dalam loop fold. Fit prior hanya dari `tr`, lalu transform `va`. Untuk final test, fit ulang menggunakan seluruh train.
City prior global	Lokasi yang sama	Lakukan pola yang sama: fit-on-train-fold, transform-validation.
Empirical transition ratio	`feature_engineering.py` line 63-74 dan 299-307	Jangan gunakan dictionary yang sudah dihitung dari seluruh target untuk menilai OOF. Bangun transition table dari training fold saja.
Fallback prior	`feature_engineering.py` line 312-320	Fallback median juga harus berasal dari training fold saat evaluasi.
Hyperparameter threshold/gamma	`train_podium_90f_gpu.py` sekitar line 244 onward	Optimasi threshold/gamma harus memakai OOF yang benar dan sebaiknya nested/holdout pada fold tuning agar tidak overfit pada OOF yang sama.

Desain fungsi baru

```
def fit_context_priors(train_part):
    cinema_prior = train_part.groupby("cinema_ids").agg(...).reset_index()
    city_prior = train_part.groupby("city_name").agg(...).reset_index()
    transition = build_transition_table(train_part)
    return cinema_prior, city_prior, transition
```

```
for fold, (tr, va) in splitter.split(...):
    priors = fit_context_priors(df_train_raw.iloc[tr])
    X_tr = build_features(..., priors=priors)
    X_va = build_features(..., priors=priors)
```

PRINSIP

Semua feature yang memakai target masa depan harus menjawab pertanyaan: "Pada tanggal ketika validation terjadi, apakah informasi ini sudah tersedia?" Jika belum, feature tidak boleh dipakai untuk mengukur OOF.

3. PO - Perbaiki Encoding XGBoost dan Reproducibility

A. Encoding categorical saat ini

```
# Saat ini (jangan dipakai lagi untuk XGB)
X_train[col] = X_train[col].astype("category").cat.codes
X_test[col] = X_test[col].astype("category").cat.codes
```

RISIKO

Train dan test dapat membuat mapping integer yang berbeda. Kategori yang sama bisa mendapat kode berbeda, sedangkan XGBoost membaca angka tersebut sebagai feature numerik.

B. Pengganti yang aman

```
from pandas.api.types import CategoricalDtype

for col in cat_cols:
    vocab = pd.Index(pd.concat([
        df_train[col].astype(str),
        df_test[col].astype(str)
    ]).unique())
    dtype = CategoricalDtype(categories=vocab)
    X_xgb[col] = X_xgb[col].astype(str).astype(dtype).cat.codes.astype("int32")
    X_xgb_test[col] = X_xgb_test[col].astype(str).astype(dtype).cat.codes.astype("int32")
```

VERSI VALIDASI

Untuk CV, vocabulary sebaiknya fit dari training fold saja; validation/test kategori yang tidak dikenal masuk ke satu 'UNKNOWN' bucket. Untuk final fit, vocabulary boleh berasal dari train penuh + kategori test yang hanya bersifat identitas, tetapi lebih aman menggunakan explicit unknown mapping.

C. Masalah weights final

Saat ini	Masalah	Ganti menjadi
`solution.ipynb` cell 23 menyimpan `clf_xgb`, `reg_xgb`, `clf_cb`, `reg_cb` terakhir.	Ini adalah model fold terakhir, bukan ensemble 5-fold yang menghasilkan prediksi final.	Simpan list/dict seluruh 5 fold, atau retrain final model penuh dengan seed dan parameter yang sama setelah memilih desain terbaik.
Submission dibuat dari rata-rata prediksi 5 fold.	Model artifact dan submission tidak identik.	Buat fungsi `predict_from_artifact()` dan generate submission dari artifact yang sama.
`.gitignore` mengabaikan `weights/`.	Tidak masalah untuk repo publik, tetapi package final harus eksplisit.	Pastikan ZIP final berisi notebook + weights yang benar-benar digunakan.

4. P0 - Ganti Validation Menjadi Competition-Like

JANGAN JADIKAN OOF 0.34738/0.34828 SEBAGAI KEBENARAN ABSOLUT DULU

Angka tersebut berguna sebagai benchmark internal repo, tetapi sebagian feature dibuat dengan statistik global. Kita perlu membuat versi clean untuk mengetahui kekuatan model yang sebenarnya.

Validation layer	Cara	Pertanyaan yang dijawab
Temporal rolling	Train pada periode lebih awal, validasi pada periode sesudahnya; setiap episode tetap 3-day history -> 7-day target.	Apakah model tahan terhadap distribution shift waktu?
Cold-start movie	Pilih film yang baru muncul pada periode validasi; jangan beri model target/history masa depan film tersebut selain 3 hari opening yang sah.	Apakah model mampu menghadapi mayoritas film test yang baru?
Cold-start cinema/city	Pisahkan entity yang baru muncul pada validation bila jumlah data memungkinkan.	Apakah fallback entity benar-benar bekerja?
Final metric	Hitung MASE persis dari scale pasangan, bukan MAE/RMSE.	Apakah optimasi benar-benar searah leaderboard?

Split yang dianjurkan

Fold A: release / episode lebih awal -> episode lebih akhir

Fold B: periode berikutnya -> periode berikutnya

Fold C: periode berikutnya -> periode berikutnya

...

Tambahkan satu benchmark cold-start khusus film baru.

Output evaluasi yang wajib dicatat untuk setiap eksperimen: overall MASE, MASE per horizon, zero-rate error, total predicted ticket, MASE untuk low-scale pairs, dan MASE untuk film cold-start.

5. P1 - Feature Engineering yang Benar-Benar Relevan

Feature block	Tindakan	Status
3-day trajectory	Pertahankan: D1/D2/D3, ratios, trend, acceleration, shares.	KEEP
MASE normalization	Pertahankan `target_z = total_ticket / scale`; benchmark dengan raw target.	KEEP + TEST
Movie-level context dari history	Tambah mean/sum/active cinema/growth film pada 3 hari terakhir.	ADD
Cinema-level context dari history	Tambah demand agregat cluster/city untuk opening window test/validation.	ADD
Calendar + holiday	Pertahankan dan tambah target-date features; pastikan mapping tanggal benar.	KEEP + VERIFY
Ticket price	Pertahankan; uji price tier dan relative price terhadap city/period jika informasi sah tersedia.	TEST
Movie metadata	Pertahankan genre/rating; normalized title wajib dipakai.	KEEP
Director/producer experience	Pertahankan hanya jika statistiknya fold-safe; jangan hitung experience dari target validation.	SAFE ONLY
Cinema chain	Tambah `chain` dari `cinema_ids` bila format konsisten.	ADD
KNN archetype	Eksperimen setelah validation clean.	LATE
Hard-coded empirical ratios	Ganti dengan table yang fit dari training fold.	REPLACE

Cinema chain

```
df["chain"] = df["cinema_ids"].astype(str).str.extract(r"^([A-Z]+)")[0].fillna("UNKNOWN")
```

PENTING

Jangan membuat daftar "studio/bintang" manual yang sangat spesifik lalu menganggapnya pasti membantu. Uji dengan ablation: tambah feature -> ukur perubahan MASE pada fold clean. Feature hanya dipertahankan jika stabil di beberapa fold.

6. P1 - Arsitektur Model yang Perlu Diuji

MODEL SAAT INI TIDAK PERLU DIBUANG

Two-stage hurdle + XGBoost/CatBoost sudah merupakan fondasi yang masuk akal karena banyak future rows bernilai nol. Kita perlu menguji varian yang lebih tepat sebelum mengganti keluarga model.

Eksperimen	Konsep	Keputusan
E1	Current hurdle baseline pada validation clean.	Anchor metodologis baru.
E2	Direct regression `z = y/scale` tanpa hurdle.	Bandingkan apakah zero modeling benar-benar memberi gain.
E3	Hurdle dengan classifier + active regressor.	Pertahankan jika menang pada low-scale dan zeros.
E4	Per-horizon direct model D4, D5, ..., D10.	Prioritas tinggi.
E5	Per-horizon hurdle.	Prioritas tertinggi setelah E3/E4.
E6	XGB + CatBoost OOF blend.	Optimalkan bobot dari OOF yang sama.
E7	Optional LightGBM branch.	Hanya bila memberi error diversity yang nyata.

Target yang diuji

```
# Target normalized
```

```
z = total_ticket / clip(scale, lower=1)
```

```
# Prediksi final
```

```
pred_ticket = clip(pred_z, lower=0) * scale
```

Per-horizon direct modeling

```
for h in range(4, 11):
```

```
    train_h = df_train[df_train["day_num_clipped"] == h]
```

```
    test_h = df_test[df_test["day_num_clipped"] == h]
```

```
    # classifier_h -> active probability
```

```
    # regressor_h -> active normalized intensity
```

```
    # combine -> pred_z_h
```

JANGAN LANGSUNG REKURSIF D4 -> D5 -> ...

Direct horizon models menghindari akumulasi error dari prediksi yang dipakai sebagai input prediksi berikutnya. Hasil akhirnya tetap harus diuji terhadap satu baseline yang sama.

7. P1/P2 - Ensemble dan Kalibrasi

A. Jangan hard-code blend 80/20 hanya karena pernah menang di public LB

Saat ini	Risiko	Perbaikan
80% anchor + 20% SOTA	Bobot ditentukan dari leaderboard/pengalaman submission, bukan OOF yang identik.	Bangun OOF prediction untuk semua branch dan cari bobot non-negative, sum=1.
50/50 XGB-CatBoost	Belum tentu optimal untuk setiap horizon.	Cari blend per horizon dari OOF, lalu uji stabilitas pada beberapa fold/time windows.
Bayesian shrinkage 14 segmen	Bisa overfit bila threshold/gamma dioptimasi pada OOF yang sama.	Tuning parameter harus dibatasi pada split tuning atau menggunakan out-of-fold meta-validation.
Hard zero preservation	Mungkin mempertahankan terlalu banyak nol bila classifier bias.	Bandingkan probability-weighted prediction vs hard zero pada clean validation.

Contoh: OOF blend search

```
preds = np.column_stack([oof_d3, oof_lgbm, oof_xgb, oof_cat, oof_hurdle])
```

Cari $w \geq 0$, $\sum(w)=1$ yang meminimalkan MASE pada OOF clean.

Jangan optimalkan lalu mengklaim hasilnya tanpa holdout kedua.

B. Weekend calibration

Jadikan sebagai eksperimen terpisah, bukan patch permanen. Uji multiplier per horizon/weekend hanya jika residual OOF menunjukkan bias yang konsisten lintas beberapa fold. Jangan mengambil angka multiplier dari keseluruhan target validation lalu menggunakannya pada fold yang sama.

8. Experiment Matrix - Jangan Eksperimen Secara Acak

ID	Hipotesis	Perubahan	Catatan keberhasilan
V0	Baseline sehat	D3 dan mean opening	Benchmark metric.
V1	Current model	Reproduce current pipeline	Pastikan hasil bisa direplikasi.
V2	No leakage	Fold-safe priors + transition	Baseline valid baru.
V3	Shared encoding	Fix XGB category mapping	Bandingkan OOF + test distribution.
V4	Test context helps	Movie/cinema/city 3-day aggregates	Lihat gain cold-start.
V5	Horizon heterogeneity	7 direct models	MASE per D4-D10.
V6	Hurdle x horizon	Classifier_h + regressor_h	Bandingkan dengan V5.
V7	Metric-aligned target	Normalized z	Compare raw vs scaled target.
V8	Model diversity	XGB + CatBoost + optional LGBM	OOF error correlation.
V9	OOF blend	Weight search from clean OOF	Holdout confirmation.
V10	Archetype transfer	KNN retention features	Only keep if stable.

ATURAN PROMOSI FEATURE/MODEL

Satu perubahan dianggap layak naik ke final hanya jika membaik pada minimal dua validation window dan tidak merusak kasus cold-start/low-scale secara tajam. Satu skor spektakuler dari satu split tidak cukup.

9. Urutan Eksekusi yang Disarankan

01	Bekukan baseline - Simpan submission dan metrik current repo. Jangan ubah banyak hal sekaligus.
02	Buat clean validation - Implement temporal + cold-start + exact MASE.
03	Fix leakage - Priors, transition ratios, medians, target-derived aggregations semuanya fold-safe.
04	Fix categorical encoding - Satu mapping / unknown bucket untuk XGB; CatBoost tetap native categorical.
05	Re-run hurdle baseline - Ini menjadi benchmark baru yang dapat dipercaya.
06	Tambahkan test-history context - Movie/cinema/city aggregate pada opening 3-day window.
07	Uji per-horizon direct - D4-D10 terpisah, lalu bandingkan dengan shared model.
08	Uji per-horizon hurdle - Classifier + active regressor per horizon.
09	Blend dari clean OOF - Optimasi bobot hanya setelah semua branch menghasilkan OOF yang sama.
10	Leaderboard A/B - Kirim submission kandidat teratas secara terkontrol; catat score dan perubahan total volume/zero-rate.
11	Lock + reproduce final artifact - Simpan semua model fold / final retrained model, lalu jalankan ulang dari clean environment. Pastikan submission yang dihasilkan identik secara angka dengan submission yang dilaporkan.

10. File-by-File Change List

File	Yang perlu dilakukan	Prioritas
`feature_engineering.py`	Refactor `EMPIRICAL_RATIO_DICT` menjadi fold-fitted transition table; pastikan priors/fallback fold-safe; tambah chain + robust history context.	P0/P1
`train_podium_90f_gpu.py`	Pindahkan prior calculation ke dalam fold; fix XGB encoding; tambah validation hooks; jangan jadikan hard-coded threshold sebagai final tanpa nested tuning.	P0
`solution.ipynb`	Samakan dengan pipeline final; jangan menyimpan only-last-fold model; buat `predict_from_artifact()`.	P0
`train_plan_b_clean_consecutive.py`	Pertahankan sebagai branch, tetapi evaluasi clean-consecutive vs all-episode pada validation yang sama.	P1
`train_plan_b_7horizon_bayes.py`	Jadikan sumber benchmark, bukan final; re-run setelah leakage dibersihkan.	P1
`train_super_ensemble.py`	Gunakan hanya setelah OOF clean; hilangkan category mismatch dan global prior leakage.	P1
`test_knn_archetype_matching.py`	Naikkan menjadi feature branch setelah baseline clean stabil.	P2
`benchmark_*	Jadikan eksperimen terpisah yang mengeluarkan tabel metrik standar; hindari notebook/script yang mencampur beberapa perubahan.	P1/P2
`README.md` + `PROGRESS_SUMMARY.md`	Perbarui angka best score agar tidak kontradiktif (README 0.47303 vs notebook 0.46890 pada snapshot repo).	P0 docs
`weights/` + final ZIP	Pastikan artifact benar-benar menghasilkan submission yang dilaporkan.	P0

11. Final Checklist Sebelum Submission

Check	Lulus jika...
Metric	MASE dihitung persis menggunakan scale per movie x cinema.
Validation	Ada temporal window dan cold-start benchmark.
Leakage	Tidak ada target-derived aggregate dari validation yang masuk ke feature validation.
Encoding	Train/valid/test menggunakan mapping yang konsisten dan unknown-safe.
Forecast shape	Setiap id test muncul tepat satu kali dan urutan id benar.
Prediction range	Tidak ada nilai negatif; kebijakan rounding/zero sudah terdokumentasi.
Zero behavior	Zero rate final dibandingkan dengan distribusi history dan residual validation, bukan sekadar dikunci mengikuti anchor.
Volume	Total predicted ticket dianalisis terhadap beberapa candidate submission.
Reproducibility	Submission dapat dibuat ulang dari notebook + weights dalam environment baru dengan SEED tetap.
Model size	Weights final tetap di bawah batas panitia yang didokumentasikan repo.
Documentation	Notebook menjelaskan data, preprocessing, feature engineering, model, metric, validasi, dan cara reproduce.
Leaderboard log	Setiap submission dicatat: experiment id, perubahan, CV MASE, LB score, total volume, zero-rate.

PESAN TERAKHIR

Jalur paling realistis untuk meningkatkan hasil sekarang bukan "menambah model sebanyak mungkin". Prioritasnya adalah membuat evaluasi benar, menghilangkan leakage, memperbaiki encoding, memanfaatkan konteks 3 hari pada test, lalu baru mengejar per-horizon hurdle dan ensemble berbasis OOF.

Audit basis: snapshot `DS\_JOINTS-main.zip` yang diberikan di percakapan. Rujukan file/line dalam dokumen mengikuti snapshot tersebut dan dapat bergeser setelah perubahan repo. Angka leaderboard/OOF disebut sebagai angka yang tertulis di repository, bukan verifikasi live Kaggle.